



MASTER ÉCONOMIE DE LA SANTÉ

DATA MINING

Analyse prédictive de la survie nette au cancer dans les pays de l'OCDE : *Une approche par arbre de décision pour l'identification des disparités de santé publique*

Ndéye BAKHOUM

Aquila WILLIAMS

ANNÉE ACADÉMIQUE 2025-2026

SOMMAIRE

I-	INTRODUCTION.....	2
II-	DESCRIPTION DE LA BASE DE DONNÉES.....	3
III-	MÉTHODOLOGIE	7
IV-	RÉSULTATS.....	9
V-	DISCUSSION	15
VI-	CONCLUSION	17
VII-	BIBLIOGRAPHIE.....	18
VIII-	TABLE DES MATIÈRES	19

I. INTRODUCTION

Quand on s'intéresse à la qualité des systèmes de santé, la survie au cancer est l'un des indicateurs les plus parlants. Ce n'est pas seulement une statistique médicale, c'est le reflet de décennies de politiques de santé publique, d'investissements en recherche, d'organisation des soins et d'accès au dépistage. Un pays qui parvient à maintenir un taux de survie au cancer du sein supérieur à 85 % ne le fait pas par hasard : c'est le résultat d'un système de dépistage organisé, de protocoles thérapeutiques bien établis et d'une prise en charge précoce. À l'inverse, un taux de survie au cancer du poumon qui stagne à 15 % dans la quasi-totalité des pays de l'OCDE interroge sur les limites actuelles de la médecine pour certaines pathologies.

C'est ce contraste qui nous a conduits à choisir ce sujet. En travaillant sur les données du programme CONCORD, intégrées dans la base "Healthcare Quality and Outcomes" de l'OCDE, nous disposons d'un jeu de données à la fois réel, complet et directement ancré dans les problématiques d'économie de la santé que nous étudions en master. L'idée de départ était simple : peut-on prédire, à partir de quelques variables simples (type de cancer, période, sexe), si un pays se situe dans une zone de survie faible, moyenne ou élevée ? Et si oui, quels sont les facteurs qui pèsent le plus dans cette prédiction ?

Pour répondre à cette question, nous avons transformé la variable continue de survie nette à cinq ans en trois classes faible, moyen et élevé afin de reformuler le problème comme une tâche de classification supervisée. Cette approche s'inscrit dans le cadre du processus KDD (Knowledge Discovery in Databases), tel qu'il a été présenté en cours, et nous a permis d'appliquer concrètement les méthodes vues en travaux dirigés à un jeu de données réel. Nous avons retenu comme modèle principal un arbre de décision (CART), pour sa lisibilité et sa capacité à produire des règles interprétables directement exploitables dans un contexte de santé publique. Afin de vérifier la robustesse de nos résultats, deux modèles supplémentaires ont également été testés en parallèle : une forêt aléatoire et une régression logistique multinomiale.

Ce rapport présente successivement la description du jeu de données, la méthodologie adoptée, les résultats obtenus et leur interprétation dans une perspective d'analyse comparative internationale des systèmes de santé.

II. DESCRIPTION DE LA BASE DE DONNEES

2.1 Source et structure générale

Les données mobilisées dans cette étude proviennent de l'Organisation de coopération et de développement économiques (OCDE), dans le cadre de la base « Healthcare Quality and Outcomes » (HCQO). Le sous-ensemble « Cancer Care » regroupe des indicateurs standardisés issus du programme international CONCORD, largement utilisé pour comparer les performances des systèmes de santé en matière de prise en charge du cancer.

L'indicateur principal étudié est la survie nette à cinq ans (exprimée en pourcentage), standardisée selon l'âge. Cette mesure permet de comparer les résultats entre pays en neutralisant les différences de structure démographique.

Après extraction et nettoyage, le jeu de données final comprend **1455 observations**, constituant une base suffisamment large pour une analyse comparative robuste à l'échelle internationale.

2.2 Description des variables

La base contient cinq variables principales.

- Les pays (46 pays représentés dans la zone OCDE),
- Le type de cancer : sept pathologies au total (poumon, sein, rectum, col de l'utérus, colon, l'estomac et la leucémie LAL)
- Le sexe (Homme / Femme),
- L'année d'observations (2004, 2009 ou 2014)
- Le taux de survie nette à cinq ans, qui va de 2,1 % à 100 % selon les cas.

Les observations correspondant à la catégorie « Total » pour la variable Sexe ont été exclues afin d'éviter les redondances, ces valeurs étant des agrégations des catégories Homme et Femme.

2.3 Prétraitement des données

Conformément au processus de découverte de connaissances dans les bases de données (KDD), plusieurs étapes de préparation ont été réalisées :

- simplification des libellés textuels (types de cancer, sexe)
- conversion des variables en facteurs
- suppression des valeurs manquantes
- transformation de la variable cible

La variable continue de survie a été discrétisée en trois classes :

Tableau 1 : Seuils de discrétisation de la variable cible


Classe	Définition
Faible	Survie < 40 %
Moyen	40 % ≤ Survie ≤ 70 %
Élevé	Survie > 70 %

Cette étape de discrétisation est essentielle pour adapter les données à une approche de classification supervisée. Elle permet également de simplifier l'interprétation des résultats en termes de niveaux de performance des systèmes de santé.

2.4 Justification de la discrétisation

L'analyse de la distribution de la variable *Survie* montre une forte dispersion des valeurs (de 2,1 % à 100 %), avec une médiane située autour de 57 % et un troisième quartile proche de 68,5 %.

Figure 1 : Histogramme de la survie avec seuils




Source : Sortie logiciel R

Les seuils retenus (40 % et 70 %) s'inscrivent ainsi dans la structure empirique des données, en distinguant trois zones clairement différenciées. Cette séparation est confirmée par un test de Kruskal-Wallis hautement significatif ($p_value < 0.05$), indiquant que les classes obtenues présentent des distributions statistiquement distinctes.

Au-delà de l'aspect statistique, ces seuils correspondent également à des niveaux de survie cliniquement contrastés, distinguant des situations de pronostic défavorable (< 40 %), intermédiaire et favorable (> 70 %).

2.5 Analyse descriptive préliminaire


Figure 2 : Répartition des classes de survie dans l'échantillon d'étude



Source : Sortie logiciel R

La distribution des classes apparaît relativement équilibrée (33,9 % Faible, 42,8 % Moyen, 23,3 % Élevé), ce qui limite les biais liés à un déséquilibre de classes et garantit des conditions favorables à l'apprentissage du modèle.


Figure 3 : Survie nette moyenne à 5 ans par type de cancer



Source : Sortie logiciel R

Cette figure met en évidence une variabilité importante selon le type de cancer. Les cancers du poumon et de l'estomac présentent des taux de survie faibles, tandis que les cancers du sein et certaines formes de leucémie affichent des niveaux de survie nettement plus élevés.


Figure 4 : Évolution temporelle du taux de survie moyen (2004–2014)



Source : Sortie logiciel R

Nous pouvons observer une progression globale des taux de survie est observée entre 2004 et 2014, suggérant une amélioration des pratiques de prise en charge au sein des pays de l'OCDE.

Figure 5 : Distribution de la survie à 5 ans par type de cancer (boxplots)



Source : Sortie logiciel R

Les différences entre pathologies sont confirmées par le test de Kruskal-Wallis ($p_value < 0.05$), indiquant que le type de cancer constitue un facteur discriminant majeur.

III. MÉTHODOLOGIE

3.1 Approche générale du data mining

Notre démarche relève de la classification supervisée : on part d'observations étiquetées (on connaît la classe de survie de chaque pays pour chaque cancer) pour entraîner un

modèle capable de prédire cette classe sur de nouvelles données. Ce type d'approche correspond exactement au cadre KDD vu en cours : préparation, exploration, modélisation, évaluation et c'est ce fil directeur qu'on a suivi tout au long du projet.

3.2 Séparation des données

On a divisé les données en deux parties : 70 % pour entraîner les modèles, 30 % pour les tester sur des observations qu'ils n'ont jamais vues. Cette séparation est stratifiée sur la variable cible, ce qui garantit que chaque sous-ensemble contient à peu près la même proportion de cas Faible, Moyen et Élevé sans ça, on risquerait d'avoir un jeu de test déséquilibré.

3.3 Validation croisée

Sur le jeu d'entraînement, on a utilisé une validation croisée à 5 plis pour choisir le meilleur paramètre de complexité (cp) de l'arbre. Concrètement, les données d'entraînement sont découpées en 5 blocs, le modèle s'entraîne sur 4 blocs et se teste sur le 5ème, et ça tourne 5 fois. On retient le cp qui donne les meilleures performances moyennes sur ces 5 tests internes. C'est plus fiable que de choisir le cp à la main ou sur un seul découpage.

3.4 Modèle principal : arbre de décision (CART)

On a retenu l'arbre de décision CART comme modèle principal, principalement pour une raison pratique : il produit des règles lisibles. Quand on travaille sur des données de santé publique, pouvoir dire "si le cancer est du poumon, alors la survie est classée Faible dans 99 % des cas" a beaucoup plus de valeur qu'un score de performance abstrait. L'arbre gère aussi naturellement les variables qualitatives comme le type de cancer ou le sexe, sans transformation particulière. Nous avons hésité entre fixer le paramètre cp manuellement et laisser la validation croisée l'optimiser, c'est finalement cette deuxième option qui a donné les meilleurs résultats (cp retenu = 0,0096).

3.5 Modèles concurrents pour comparaison

Pour ne pas s'arrêter à un seul modèle, on a aussi entraîné une **forêt aléatoire (Random Forest)** et une **régression logistique multinomiale** sur les mêmes données, avec la

même procédure. L'idée était simple : si un modèle plus complexe fait mieux, on devrait le choisir. Si les performances sont identiques, ça justifie de rester sur le modèle le plus simple et le plus lisible.

3.6 Mesures de performance

Les performances des modèles ont été évaluées à l'aide de plusieurs indicateurs complémentaires :

- Accuracy (précision globale) : proportion de prédictions correctes
- Kappa de Cohen : mesure de l'accord corrigé du hasard
- Sensibilité (Recall) : capacité à détecter correctement chaque classe
- Spécificité : capacité à exclure les autres classes
- Score F1 : compromis entre précision et rappel

Ces indicateurs ont été calculés à la fois globalement et pour chaque classe, afin d'évaluer l'équilibre du modèle.

3.7 Analyse de l'importance des variables

Une fois l'arbre construit, il est important de déterminer les variables qui contribuent le plus. Cette mesure d'importance basée sur la réduction d'impureté à chaque nœud permet de vérifier empiriquement si nos hypothèses de départ sont confirmées.

3.8 Vérification du sur-apprentissage

Enfin, on a comparé les performances du modèle sur le jeu d'entraînement et sur le jeu de test. Un modèle qui "mémorise" les données d'entraînement sans vraiment apprendre sera excellent sur ces données mais mauvais sur les données de test, c'est le sur-apprentissage. Un écart de moins de 3 points entre les deux est généralement considéré comme acceptable.

IV. RÉSULTATS

4.1 Performance globale du modèle

L'évaluation du modèle d'arbre de décision a été réalisée sur un échantillon de test indépendant (30 % des données), conformément aux bonnes pratiques en data mining. Les performances obtenues témoignent d'une excellente capacité de généralisation.

Le modèle atteint une précision globale (accuracy) de **91,71 %**, accompagnée d'un coefficient Kappa de **0,87**, indiquant un accord très élevé entre les classes prédites et observées, bien au-delà du hasard.

Ces résultats confirment la pertinence de l'approche retenue et suggèrent une structuration marquée des données autour de la variable cible.

4.2 Analyse de la matrice de confusion

Tableau 2 : Matrice de confusion du modèle de classification

	Réf. : Faible	Réf. : Moyen	Réf. : Élevé
Prédit : Faible	142	6	0
Prédit : Moyen	5	173	12
Prédit : Élevé	0	7	89

Source : Sortie logiciel R


L'analyse détaillée de la matrice de confusion met en évidence une excellente capacité du modèle à distinguer les trois classes de survie.

- La classe **Faible** est prédite avec une sensibilité de 95,9 %, traduisant une très bonne identification des situations à faible survie
- La classe **Moyen** présente une sensibilité de 89,8 %, avec quelques confusions marginales avec les classes adjacentes
- La classe **Élevé** atteint une sensibilité de 89,1 %, confirmant une bonne détection des cas à pronostic favorable

Les erreurs de classification observées restent principalement localisées aux frontières entre classes (Moyen vs Élevé), ce qui est cohérent avec le processus de discrétisation de la variable cible.

4.3 Visualisation du modèle : arbre de décision

Figure 6 : Arbre de décision (CART) pour la classification de la survie au cancer



Source : Sortie logiciel R

L'arbre de décision permet d'interpréter directement les règles de classification. Le premier nœud de division repose sur le type de cancer, confirmant son rôle central dans la prédiction.


Certaines règles décisionnelles caractéristiques peuvent être extraites :

- Les cancers du poumon et de l'estomac sont majoritairement associés à une classe de survie faible
- Les cancers du sein et certaines formes de leucémie sont fortement liés à une survie élevée
- Les cancers intermédiaires (côlon, rectum) se situent principalement dans la classe moyenne, avec des variations selon le contexte

Cette structure hiérarchique reflète fidèlement les connaissances cliniques actuelles, tout en offrant une formalisation explicite des règles de décision.

4.4 Importance des variables

Figure 7 : Importance relative des variables dans le modèle



Source : Sortie logiciel R

L'analyse de l'importance des variables confirme la domination du facteur *Cancer*, qui concentre l'essentiel du pouvoir explicatif du modèle.

Les autres variables présentent une contribution nettement plus faible :

- Le sexe exerce une influence marginale
- La variable année apparaît comme quasi négligeable dans le processus de classification

Ces résultats mettent en évidence une hiérarchie claire des déterminants, dominée par la nature de la pathologie.

4.5 Synthèse des performances par classe

Tableau 3 : Indicateurs de performance par classe

Classe	Sensibilité	Spécificité	Score F1
Faible	0,9592	0,9617	0,9431
Moyen	0,8978	0,9315	0,9027
Élevé	0,8911	0,9760	0,9045

Source : Sortie logiciel R

Ces indicateurs confirment la robustesse du modèle sur l'ensemble des classes, avec un léger avantage pour la détection des situations de survie faible, ce qui peut être particulièrement pertinent dans une perspective de santé publique.

4.6 Comparaison avec des modèles concurrents

Afin de renforcer la validité des résultats, deux modèles supplémentaires ont été entraînés sur les mêmes données :

- Forêt aléatoire (*Random Forest*),
- Régression logistique multinomiale.

Les performances obtenues sont strictement identiques pour les trois approches :

Tableau 4 : Comparaison des modèles

Modèle	Accuracy	Kappa	F1 (Faible)	F1 (Moyen)	F1 (Élevé)
Arbre de décision (CART)	0,917	0,872	0,943	0,903	0,905
Random Forest	0,917	0,872	0,943	0,903	0,905
Régression logistique multinomiale	0,917	0,872	0,943	0,903	0,905

Source : Sortie logiciel R

Nos trois modèles donnent exactement les mêmes résultats, ce qui est surprenant. Au début on a cru à une erreur dans le code mais après vérification, les résultats sont bien reel.

4.7 Vérification de l'absence de sur-apprentissage

La comparaison des performances entre le jeu d'entraînement et le jeu de test permet d'évaluer la robustesse du modèle :

- Accuracy (entraînement) : 0,933
- Accuracy (test) : 0,917

L'écart observé (1,63 point) reste faible, ce qui indique l'absence de sur-apprentissage significatif. Le modèle présente ainsi une bonne capacité de généralisation, renforçant la fiabilité des résultats obtenus

4.8 Interprétation globale des résultats

Dans l'ensemble, le modèle (CART) présente des performances élevées tout en conservant une forte interprétabilité. La cohérence entre les résultats statistiques, la structure de l'arbre et les connaissances médicales renforce la validité de l'approche.

La qualité des performances observées s'explique en grande partie par la structuration intrinsèque des données : le type de cancer constitue un signal prédictif dominant, permettant une séparation nette des classes de survie.

Toutefois, cette forte dépendance à une variable unique invite à une lecture prudente des résultats, en particulier dans une perspective de généralisation à des contextes cliniques plus complexes.

L'absence de différence entre les modèles constitue un résultat central de l'analyse. Elle indique que la structure des données est dominée par une variable explicative majeure : le type de cancer.

Dans ce contexte, même des modèles plus complexes, capables de capturer des interactions non linéaires, n'apportent pas de gain prédictif significatif. La frontière de décision entre les classes apparaît relativement simple et déjà capturée par un modèle interprétable.

Ce résultat justifie a posteriori le choix du modèle CART, qui offre un excellent compromis entre performance et lisibilité

V. DISCUSSION

Les résultats que nous avons obtenus sont, il faut le dire, assez nets. Avec une précision de 91,7 % et un Kappa de 0,87, le modèle classe bien les trois niveaux de survie et ce qui nous a le plus frappé, c'est que les trois approches testées (arbre de décision, forêt aléatoire, régression logistique multinomiale) aboutissent strictement aux mêmes performances. Dans notre cas, cela s'explique par la domination très marquée du type de cancer : dès que l'on connaît la pathologie, la classe de survie est presque déterminée. Le cancer du poumon classe systématiquement en "Faible", la leucémie LAL infantile et le cancer du sein en "Élevé". Ce résultat n'est pas surprenant si l'on connaît la littérature, CONCORD-3 (Allemani et al., 2018) montre exactement ces mêmes hiérarchies à l'échelle mondiale mais il est rassurant de le retrouver dans notre modèle, car cela valide la cohérence de l'approche. La forêt aléatoire, pourtant réputée plus robuste face aux données complexes, n'apporte ici aucun gain, ce qui confirme que la frontière entre les classes est relativement simple et déjà bien capturée par un arbre unique.

Un autre résultat mérite d'être discuté : le rôle du sexe. Le test de Wilcoxon révèle une différence statistiquement significative entre hommes et femmes ($p < 0.05$), et pourtant cette variable n'apparaît qu'en septième position dans l'importance des variables du modèle, avec une contribution de moins de 3 %. Ce décalage illustre quelque chose d'important que l'on oublie parfois : une variable peut être statistiquement significative sans être réellement utile pour prédire. La significativité détecte l'existence d'une différence dans les données, l'importance prédictive mesure si cette différence aide vraiment à classer. Dans un jeu de données de plus de 1 400 observations, même un effet minuscule devient significatif, c'est simplement une question de puissance statistique. De la même façon, la variable Année est quasi nulle dans le modèle, malgré le test de Kruskal-Wallis significatif ($p = 0,006$) : les progrès entre 2004 et 2014 ont amélioré la survie globalement, mais sans changer la hiérarchie entre cancers. Concernant la robustesse, l'écart entre les performances sur le jeu d'entraînement (93,3 %) et le jeu de test (91,7 %) n'est que de 1,63 point, ce qui indique clairement l'absence de sur-apprentissage et une bonne capacité de généralisation du modèle.

Cela dit, ce travail comporte plusieurs limites. La première est liée à la discrétisation : transformer un taux continu en trois catégories simplifie forcément la réalité. Un pays avec

69 % de survie et un autre avec 71 % se retrouvent dans des classes différentes, alors qu'ils sont cliniquement très proches. Nous avons essayé de minimiser ce problème en choisissant des seuils ancrés dans la distribution des données et validés statistiquement, mais l'effet de seuil reste une limite réelle. La deuxième limite, peut-être plus fondamentale, est que nous travaillons sur des moyennes nationales. On ne peut pas en déduire grand-chose sur la survie d'un patient individuel, c'est le problème classique du sophisme écologique. Notre modèle décrit des tendances agrégées, pas des causalités individuelles.

Malgré ces limites, les résultats ont des implications concrètes pour la santé publique. L'identification claire des cancers associés à une survie faible, poumon et estomac en tête devrait orienter les efforts vers le dépistage précoce et l'amélioration des protocoles thérapeutiques pour ces pathologies spécifiques. À l'inverse, les taux élevés observés pour la leucémie LAL infantile illustrent ce que des investissements ciblés en recherche et en organisation des soins peuvent produire sur plusieurs décennies.

Par ailleurs, les disparités entre pays pour un même cancer particulièrement visibles dans les boxplots de la leucémie LAL, rappellent que la pathologie n'explique pas tout : les systèmes de santé, leur financement et leur organisation jouent un rôle que ce modèle ne capture pas entièrement. Ce qui ressort finalement de ce projet, au-delà des chiffres, c'est qu'en économie de la santé, l'interprétabilité d'un modèle compte autant que sa performance. Nous aurions pu forcer des modèles plus complexes pour gagner quelques dixièmes de point mais face à un décideur de santé publique, un arbre de décision qu'on peut lire et expliquer en cinq minutes à plus de valeur pratique qu'un Random Forest dont les mécanismes restent opaques.

C'est d'ailleurs ce que Kourou et al. (2015) soulignent dans leur revue sur le machine learning en oncologie. Pour prolonger ce travail, il faudrait idéalement accéder à des données individuelles (stade, traitement reçu, niveau socio-économique) pour construire un vrai outil prédictif patient. En l'état, notre modèle est plutôt un outil de veille et de comparaison internationale, ce qui reste utile, mais différent d'un outil clinique à proprement parler.

VI. CONCLUSION

Ce travail avait pour objectif d'effectuer une analyse prédictive de la survie au cancer dans les pays de l'OCDE à travers une approche de data mining, en mobilisant des méthodes de classification supervisée.

Les résultats obtenus montrent que les modèles développés présentent des performances élevées, avec une précision supérieure à 91 %. La comparaison entre plusieurs approches (arbre de décision, forêt aléatoire et régression logistique multinomiale) met en évidence une convergence des performances, suggérant que la structure des données est fortement marquée et que la variable cible est relativement bien séparée.

Parmi les variables étudiées, le type de cancer apparaît clairement comme le facteur prédictif dominant. Ce résultat, cohérent avec la littérature épidémiologique, souligne l'importance des caractéristiques biologiques et cliniques des pathologies dans la détermination du pronostic. À l'inverse, les variables démographiques et temporelles jouent un rôle plus secondaire dans le cadre de cette modélisation.

Le choix de l'arbre de décision comme modèle principal se justifie par sa capacité à fournir une représentation explicite et interprétable des règles de classification. Dans un contexte de santé publique, cette lisibilité constitue un atout important pour faciliter la compréhension et l'utilisation des résultats par les acteurs non spécialistes des méthodes statistiques.

Toutefois, plusieurs limites doivent être prises en compte. La discrétisation de la variable de survie simplifie un phénomène continu et peut introduire des effets de seuil. De plus, l'utilisation de données agrégées au niveau des pays expose l'analyse au risque de sophisme écologique, limitant la portée des conclusions à l'échelle individuelle.

Malgré ces limites, ce travail met en évidence l'intérêt des approches de data mining pour analyser des données de santé à grande échelle et identifier des structures sous-jacentes pertinentes. Il montre également que la performance d'un modèle ne doit pas être le seul critère de choix, et que l'interprétabilité joue un rôle central, en particulier dans des domaines sensibles comme la santé.

VII. BIBLIOGRAPHIE

Allemani, C. et al. (2018). Global surveillance of trends in cancer survival 2000-14 (CONCORD-3). The Lancet, 391(10125), 1023–1075.

Kourou, K. et al. (2015). Machine learning applications in cancer prognosis and prediction. Computational and Structural Biotechnology Journal, 13, 8–17.

Kuhn, M. (2008). Building Predictive Models in R Using the caret Package. Journal of Statistical Software, 28(5), 1–26.

Landis, J.R. & Koch, G.G. (1977). The Measurement of Observer Agreement for Categorical Data. Biometrics, 33(1), 159–174.

OCDE (2025). Base de données sur la qualité des soins de santé Soins du cancer. Explorateur de données OCDE.

<https://data-explorer.oecd.org>

R Core Team (2024). R: A language and environment for statistical computing. R Foundation for Statistical Computing, Vienne.

Ronchetti Jérôme, Data Mining (“fouille”/”exploration”) de données), Master1 Economie de la santé

VIII. TABLE DES MATIÈRES

SOMMAIRE	1
I. INTRODUCTION.....	2
II. DESCRIPTION DE LA BASE DE DONNEES	3
1. Source et structure générale	3
2. Description des variables	3
3. Prétraitement des données.....	3
4. Justification de la discrétisation.....	4
5. Analyse descriptive préliminaire	5
III. METHODOLOGIE	7
1. Approche générale du data mining	7
2. Séparation des données	8
3. Validation croisée	8
4. Modèle principale : arbre de décision	8
5. Modèle concurrents pour comparaison	8
6. Mesures de performance	9
7. Analyse de l'importance des variables	9
8. Vérification du sur-apprentissage	9
IV. RESULTATS	9
1. Performance globale du modèle.....	9
2. Analyse de la matrice de confusion.....	10
3. Visualisation du modèle : arbre de décision.....	10
4. Importance des variables	12
5. Synthèse des performances par classe	12
6. Comparaison avec des modèles concurrents.....	13
7. Vérification de l'absence de sur-apprentissage.....	14
8. Interprétation globale des résultats	14
V. DISCUSSION.....	15
VI. CONCLUSION.....	17
VII. BIBLIOGRAPHIE	18
VIII. TABLE DES MATIERES.....	19